

Capitolo 5

Conclusioni

Il Capitolo 1 ha dichiarato tre obiettivi per questo lavoro: efficienza, equità e generalizzazione. Questo capitolo li riprende uno a uno alla luce dei risultati del Capitolo 4, indica le direzioni lasciate aperte e discute infine i limiti dello studio.

Il confronto di base (§4.4.1) conferma che sia MaxPressure sia MetaSTGAT Pro battono nettamente Fixed-Time su ogni metrica, con l'unica eccezione del max wait in training, dove la rotazione fissa delle fasi di Fixed-Time impone per costruzione un limite all'attesa che le configurazioni di training, meno dense, non arrivano a violare, limite che però sparisce non appena il traffico si fa più intenso in test. Tra MaxPressure e Pro il compromesso al centro di questo lavoro emerge già a questo livello. MaxPressure resta la scelta più efficiente in media, Pro riduce il $wait_{\max}$ del 34-41% pur restando entro pochi punti percentuali su travel time medio.

Lo studio sul peso α quantifica questo compromesso direttamente. Al diminuire di α , il $wait_{\max}$ e $tt_{\max}$ peggiorano in modo pressoché monotono, un gradiente netto e prevedibile: più equità si chiede alla ricompensa, più il controllore la garantisce. Il travel time medio non peggiora invece in modo altrettanto sistematico. $\alpha = 0.04$ lo riduce persino sotto quello di MaxPressure in test, il primo caso in questo lavoro in cui una variante RL supera MaxPressure su questa metrica in generalizzazione.

Il caso $\alpha = 0$ va però letto con un'avvertenza, perché non è il punto finale di quel gradiente ma un caso a parte. Rimuovere del tutto la penalità, lasciando intatti stato, maschera e vincolo di visibilità, produce un blocco quasi totale di un veicolo per l'intera durata dell'episodio su quattro dei cinque seed della griglia 5×5 più densa mai vista in training, il risultato peggiore misurato in questo lavoro tra i modelli con il resto della procedura invariato. Questo non dimostra però che rimuovere il termine di equità comprometta sempre e comunque la garanzia osservata: è più probabile che qui a fallire sia lo specifico allineamento tra stato e ricompensa di questo modello. Il vettore w_i^t , il segnale di attesa per corsia, resta nello

stato osservato dalla rete anche quando $\alpha = 0$ ne azzerava il peso nell’obiettivo, per cui l’agente continua a vedere un segnale che l’addestramento non penalizza più, un disallineamento che probabilmente confonde l’ottimizzazione più di quanto farebbe la sola assenza del termine di equità. Per questo motivo, nonostante $\alpha = 0.04$ sia leggermente più efficiente in media, questo lavoro adotta $\alpha = 0.08$ come riferimento per gli studi successivi, coerentemente con la priorità dichiarata tra le metriche: è la configurazione più incisiva proprio sulle due metriche di caso peggiore che questo lavoro tiene in primo piano.

Lo studio di ablation isola un effetto complementare. Dei cinque preset confrontati, solo i due che rimuovono interamente il segnale di attesa dallo stato o dalla ricompensa (`paper` ed `environment`) degradano marcatamente verso il comportamento di MaxPressure, mentre le tre varianti che disattivano singolarmente meccanismi dell’algoritmo di apprendimento (`temporal`, `single_dqn`, `vanilla_buffer`) restano vicine al riferimento o lo superano su alcune metriche. Su 35 istanze di test, `paper` ed `environment` sono gli unici, insieme a MaxPressure, a bloccare un veicolo per quasi l’intera durata dell’episodio; nessuna delle varianti che conserva stato e ricompensa lo fa mai. La garanzia di equità di questo lavoro dipende quindi dalla combinazione di segnale di attesa nello stato e termine di ricompensa dedicato, non da un singolo dettaglio implementativo dell’algoritmo di apprendimento sottostante.

Il confronto tra meccanismi spaziali aggiunge una terza componente necessaria. A parità di stato, ricompensa e maschera, MetaSTGCN (l’unico meccanismo a peso di aggregazione fissato dalla sola topologia, non appreso per coppia di nodi) resta sistematicamente indietro su ogni metrica, in un caso peggiore persino di MaxPressure nel proprio stesso regime di addestramento. Equità ed efficienza non sono quindi solo una funzione della ricompensa, richiedono anche un meccanismo di comunicazione capace di instradare il segnale del vicino in difficoltà fino a chi può agire su di esso.

Ogni modello di questo lavoro è addestrato una sola volta su una griglia 4×4 e valutato, senza riaddestramento, su topologie più grandi (5×5 , 6×6), su una spaziatura stradale diversa e su profili di traffico differenti. Il risultato principale è positivo ma non uniforme. Sulle configurazioni mai viste in training, MetaSTGAT Pro conserva il proprio vantaggio su MaxPressure e Fixed-Time su tutte le metriche principali, e le varianti che disattivano meccanismi dell’algoritmo di apprendimento (`single_dqn`, `vanilla_buffer`) mostrano un vantaggio sul riferimento concentrato quasi esclusivamente su queste topologie più grandi. Alla scala di training, lo stesso vantaggio si riduce o si inverte a seconda della metrica, segno che quei meccanismi aiutano soprattutto la generalizzazione di scala, non le prestazioni in senso assoluto.

Un secondo asse di generalizzazione, la spaziatura stradale, rivela un meccanismo distinto. Il preset `environment`, che tra le altre cose disattiva il vincolo sul campo visivo, degrada in modo sproporzionato proprio sulle due configurazioni con spaziatura di 200 metri, mai viste in training a nessuna spaziatura diversa da 100 metri. La causa più diretta è che quel vincolo limita per costruzione lo scarto tra la distribuzione di training e quella di test; senza di esso, il modello osserva conteggi di veicoli mai incontrati durante l'addestramento. Lo stesso pattern, attenuato, si osserva nel margine di vantaggio di `single_dqn` e `vanilla_buffer` sul max wait, che si restringe quasi a scomparire sulle configurazioni a 200 metri pur restando ampio sulle griglie più grandi. Generalizzare a una scala di rete diversa e generalizzare a una spaziatura fisica diversa non sono la stessa cosa, e i meccanismi che aiutano l'una non aiutano necessariamente l'altra.

Il caso di MetaSTSONAR chiude il quadro con un risultato meno atteso: a parità di ogni altro fattore, $L = 2$ ricorrenze di propagazione superano $L = 4$ su $tt_{\max}$ sia in training sia in test, quando il vantaggio teorico di un campo recettivo più ampio suggerirebbe l'opposto. Poiché lo svantaggio di $L = 4$ è già presente alla scala di training, dove non c'è alcun cambio di topologia da spiegare, la causa non può essere una generalizzazione peggiore. È più plausibile un limite legato all'ottimizzazione, dato che il gradiente deve retropropagare attraverso il doppio dei passi dell'equazione di propagazione a parità di procedura di training, un compito via via più difficile quanto più L cresce. Questo lavoro non arriva a isolare in modo conclusivo se sia davvero questa la causa.

I risultati discussi finora aprono la strada a diverse direzioni di ricerca, quasi tutte riconducibili alle stesse semplificazioni strutturali dichiarate nella descrizione dell'ambiente di simulazione (Capitolo 3). Un primo esperimento a basso costo sarebbe aumentare il numero di episodi di addestramento oltre i cento usati in questo lavoro, per verificare se lo svantaggio di MetaSTSONAR a $L = 4$ discusso sopra sia davvero un limite di ottimizzazione o solo una convergenza più lenta che un budget di addestramento maggiore risolverebbe da sé.

Le altre direzioni riguardano la generalizzazione a reti stradali strutturalmente diverse da quelle qui testate. Le griglie di questo lavoro hanno segmenti stradali di lunghezza uniforme, un vincolo che una rete con strade di lunghezza eterogenea rimuoverebbe, mettendo alla prova un modello il cui campo visivo e la cui nozione di distanza tra nodi sono stati calibrati proprio su quella uniformità. Le intersezioni sono inoltre tutte a quattro vie e ad angolo retto, mentre una griglia irregolare, con angoli diversi da novanta gradi o incroci a tre o cinque vie, metterebbe alla prova la struttura a fasi fisse qui adottata. Le vie a senso unico cambierebbero a loro volta

la struttura dei conflitti tra movimenti alla base della stessa definizione di fase, un asse di variazione distinto da quelli già esplorati. Più in generale, ciascuna delle semplificazioni elencate tra le assunzioni del modello di simulazione, dai limiti di velocità uniformi su ogni strada alla loro relativa omogeneità, è un candidato naturale per un futuro studio di generalizzazione, così come l'estensione della valutazione a topologie stradali reali oltre alle griglie sintetiche qui utilizzate.

Vale la pena di notare come molte di queste differenze strutturali, la lunghezza di una strada, il suo limite di velocità, l'angolo di un incrocio, potrebbero essere incorporate senza modificare l'architettura di base, aggiungendole semplicemente alle meta-feature già usate dal meta-learner di questo lavoro per condizionare i pesi di ciascun nodo sulle sue caratteristiche locali. Un'ultima direzione, di natura diversa dalle altre, è l'introduzione di mezzi pubblici e pedoni accanto al solo traffico veicolare privato modellato in questo lavoro: un'estensione che richiederebbe fasi e segnali dedicati, non la sola aggiunta di una nuova meta-feature.

Nonostante i risultati ottenuti, alcuni limiti vanno considerati nell'applicazione pratica di questo lavoro. Ogni modello, RL o ablation, deriva da un singolo run di addestramento. La batteria a più seed introdotta nel protocollo sperimentale ripete la sola valutazione, non l'addestramento, per cui buona parte dei risultati più sottili discussi in questo capitolo resta compatibile, oltre che con le spiegazioni proposte, con la varianza tra run di addestramento indipendenti diversi dall'unico osservato. Il confronto tra meccanismi spaziali, come già notato, non pareggia il numero di parametri tra le tre famiglie confrontate. Una parte del divario osservato, specialmente a sfavore di MetaSTGCN, potrebbe in principio riflettere anche questa differenza, non solo la capacità espressiva del meccanismo di aggregazione in sé. La valutazione di generalizzazione resta inoltre confinata a reti sintetiche a griglia regolare, generate parametricamente, mai a una rete stradale reale, un limite che questo lavoro condivide con la maggior parte della letteratura citata nell'introduzione, e che la sola estensione a griglie più grandi non risolve. Allo stesso modo, CITYFLOW privilegia la velocità di simulazione sul realismo microscopico del singolo veicolo (§2.5). Risultati assoluti su un simulatore più dettagliato, o su dati reali, potrebbero differire pur lasciando invariate le conclusioni relative tra i controllori confrontati. Infine, il confronto tra modelli in questo lavoro non include un test di significatività statistica in senso classico. La consistenza osservata su più configurazioni di test e più seed di valutazione rende i risultati qualitativamente solidi, non un sostituto formale di un test di ipotesi.