

Sommario

Il traffico veicolare nelle aree urbane attraversa incroci regolati da semafori, e il modo in cui le fasi vengono decise incide sui tempi di percorrenza e sulla congestione della rete. Le soluzioni classiche, dai piani a tempi fissi ai sistemi coordinati come SCOOT e SCATS, si basano su euristiche definite manualmente e restano per questo poco flessibili di fronte a condizioni di traffico diverse da quelle previste in fase di progettazione. Il reinforcement learning offre un'alternativa, apprendendo una politica di controllo dall'esperienza simulata; le architetture più recenti coordinano gli agenti di intersezioni vicine tramite reti neurali a grafo, ma tendono a concentrarsi sull'efficienza aggregata, senza trattare l'equità tra le direzioni di traffico come obiettivo esplicito né verificare sistematicamente la generalizzazione a condizioni mai osservate in addestramento.

Questo lavoro usa come punto di partenza MetaSTGAT, un'architettura in cui ogni incrocio è controllato da un agente che apprende e gli agenti si scambiano informazioni con gli incroci vicini tramite una rete neurale a grafo, per condurre uno studio sperimentale del compromesso tra efficienza, equità e generalizzazione. L'ambiente, costruito su CityFlow, riproduce reti a griglia di tre dimensioni con traffico generato parametricamente; il confronto include le baseline Fixed-Time e Max-Pressure ed è organizzato in tre studi indipendenti, sul peso assegnato all'equità nella ricompensa, su un'ablazione sistematica delle modifiche introdotte, e sul meccanismo di comunicazione tra intersezioni. Ogni modello è valutato, senza riaddestramento, su topologie, spazature e profili di traffico mai incontrati in addestramento.

Il modello di riferimento riduce l'attesa massima subita dai veicoli del 34% in addestramento e del 41% in valutazione rispetto a Max-Pressure, a fronte di un tempo di percorrenza medio superiore di pochi punti percentuali. Sulle topologie più grandi mai viste in addestramento, Max-Pressure arriva a bloccare almeno un veicolo per l'intera durata dell'episodio in ogni configurazione testata, mentre il modello di riferimento resta entro limiti nettamente più contenuti. L'ablazione mostra inoltre che questo vantaggio dipende dalla combinazione tra il segnale di attesa nello stato

e il termine dedicato nella ricompensa, non da un singolo dettaglio dell'algoritmo di apprendimento.

Questi risultati indicano che l'equità tra direzioni di traffico può essere perseguita senza una rinuncia sostanziale all'efficienza, e che parte di questo vantaggio si conserva su condizioni diverse da quelle di addestramento.